이메일 마케팅 실험 데이터 프로파일링 보고서

대상: Hillstrom E-Mail Analytics Challenge | 기준 데이터: 업로드 원본 CSV | 작성일: 2026-10-14

보고 범위: 원본 파일의 구조와 기초 통계 프로파일링. 데이터 정제, 캠페인 효과 추정, 가설 검정은 수행하지 않음.

1. 데이터 개요

항목	직접 확인된 내용
파일명	Kevin_Hillstrom_MineThatData_E-MailAnalytics_DataMiningChallenge_2008.03.20.csv
형식 및 테이블	CSV / 단일 테이블
전체 행·열	64,000행 / 12열
자료형	pandas 기준 int64 6개, float64 2개, object 4개
날짜형 컬럼	없음
결측 및 동일 행	결측 셀 0개 / 완전히 동일한 행 6,562개
데이터 관계	별도 테이블이 없어 JOIN 관계 없음; 고유 고객 ID 컬럼은 확인되지 않음

해석 주의: 완전히 동일한 행은 서로 다른 고객일 수 있으며, 6,562건을 중복 고객으로 해석하거나 삭제해서는 안 됩니다.

2. 컬럼 명세 및 고유값

컬럼	dtype	구분	고유값	결측	의미 (미확정 내용은 추정 표기)	활용
recency	int64	이산 숫자	12	0	최근 구매 이후 경과 기간 (단위 추가 확인)	보조
history_segment	object	범주	7	0	과거 구매액 구간	보조
history	float64	연속 숫자	34833	0	과거 구매액 (USD)	보조
mens	int64	이진 범주	2	0	남성용 상품 관련 구매 이력 여부 (추정)	보조
womens	int64	이진 범주	2	0	여성용 상품 관련 구매 이력 여부 (추정)	보조
zip_code	object	범주	3	0	지역 유형; 실제로는 우편번호가 아닌 3범주	보조
newbie	int64	이진 범주	2	0	신규 고객 여부 (추정)	보조
channel	object	범주	3	0	고객 이용·구매 채널 (추정)	보조
segment	object	범주	3	0	무작위 실험 이메일 배정 유형	핵심
visit	int64	이진 범주	2	0	사후 웹사이트 방문 여부 (ITT 필터 사용 금지)	제한
conversion	int64	이진 범주	2	0	관측 기간 구매 여부	핵심
spend	float64	연속 숫자	429	0	관측 기간 고객 구매 금액 (USD)	핵심

컬럼 의미는 업로드된 프로젝트 기획서의 설명을 참고했습니다. 데이터 값만으로 확정할 수 없는 항목은 추정으로 구분했습니다.

3. 주요 변수 빈도

실험 배정 (segment)	행 수	전체 대비 비중
Womens E-Mail	21,387	33.42%
Mens E-Mail	21,307	33.29%
No E-Mail	21,306	33.29%

변수	구성/빈도
conversion	0: 63,422 / 1: 578
visit	0: 54,606 / 1: 9,394
spend	0: 63,422 / 양수: 578 / 음수: 0
zip_code	Surburban: 28,776, Urban: 25,661, Rural: 9,563
channel	Web: 28,217, Phone: 28,021, Multichannel: 7,762
history_segment	7개 구간; 가장 빈도 높은 범주: 1) $0 - $100 (22,970행)

4. 주요 숫자형 변수 기초 통계

통계량	recency	history (USD)	spend (USD)
관측 수	64,000	64,000	64,000
평균	5.76	242.09	1.05
표준편차	3.51	256.16	15.04
최솟값	1.00	29.99	0.00
25%	2.00	64.66	0.00
중앙값	6.00	158.11	0.00
75%	9.00	325.66	0.00
최댓값	12.00	3,345.93	499.00

관찰: spend의 중앙값 및 75% 분위수는 0이며, 평균은 약 $1.05입니다. 이는 전체 배정 행의 기초 통계로, 발송 효과를 뜻하지 않습니다.

5. 검증 필요사항 및 후속 조치

검토 항목	현재 상태 / 권장 후속 검증
관측 단위	고객 고유 ID 없음. 원본 데이터 설명으로 1행=고객 1명 및 14일 관측 기준 확인
동일 행 6,562개	실제 중복 고객이라고 단정 불가. 삭제하지 않고 원본 유지
범주 표기	zip_code 값 Surburban 확인. 출처 정의 확인 전 자동 보정 금지
성과 변수 일관성	conversion=1과 spend>0은 각각 578건. 동일 행에서 일치하는지는 품질 진단 때 교차 검증
무작위 배정	세 집단 존재 확인. 사전 특성 균형과 실험 배정 근거는 별도 검증
비용·장기 성과	발송 비용/마진/장기 구매내역/날짜별 원자료 없음. ROI·LTV·일별 추세 분석 대상 제외
모호한 컬럼 의미	recency의 기간 단위, mens·womens·newbie·channel의 세부 정의는 데이터 사전 확인 필요

6. 결론 및 승인 대상

Q1(전체 전환 효과), Q2(유형별 차이), Q3(고객당 증분 매출)에 필요한 segment·conversion·spend가 모두 존재합니다. 다만 실험 설계와 관측 단위, 값의 일관성은 추가 검증해야 하므로 본 보고서만으로 인과 효과 분석 완료를 선언하지 않습니다.

다음 단계 권고: 원본 보존 상태에서 데이터 품질 진단(값의 범위, 집단별 일관성, 동일 행, 극단값, 사전 특성 균형)을 수행한 뒤 정제 여부를 사용자 승인으로 결정합니다.

자료 근거: 업로드 CSV에 대해 pandas.read_csv, dtypes, nunique, isna, duplicated, value_counts, describe를 실행하여 재확인. 컬럼 설명 및 분석 목적은 업로드 기획서 참고.