최종 데이터 정제·통합 결과 보고서

프로젝트: 이메일 마케팅 캠페인의 실제 효과 검증 | 검증 기준: 업로드된 원본 CSV 및 실행 로그

1. 최종 결론

검증 결과 원본 데이터 64,000행과 기존 12개 컬럼의 값은 최종 분석 마스터에서 모두 보존되었습니다. 추가된 컬럼은 segment를 기반으로 생성한 email_assigned 1개뿐입니다. 실제 삭제·값 대체·이상치 제거는 수행하지 않았으며, JOIN도 없습니다. EDA 진행에 적합하되 고객 고유 식별자와 날짜 정보의 부재는 분석 한계로 유지합니다.

2. 정제·통합 전후 품질 검증

검증 항목	원본 CSV	최종 마스터	판정 / 근거
행 수	64,000	64,000	통과 · 행 손실 0
열 수	12	13	통과 · 파생 변수 1개 추가
결측 셀	0	0	통과 · 증가 없음
완전 동일 행	6,562	6,562	통과 · 삭제 없음
기존 12컬럼 값	원본 기준	전 행 동일	통과 · 값 불일치 0
전환 건수	578	578	통과 · 합계 일치
spend 합계	$67,258.13	$67,258.13	통과 · 합계 일치
JOIN 및 행 손실	해당 없음	미수행	통과 · 결합 실패 없음
email_assigned	없음	0 / 1	통과 · 불일치 0

3. 숫자형 변수의 분포 보존

변수	평균(전 → 후)	중앙값(전 → 후)	최댓값(전 → 후)
recency	5.7637 → 5.7637	6 → 6	12 → 12
history	242.0857 → 242.0857	158.11 → 158.11	3,345.93 → 3,345.93
spend	1.0509 → 1.0509	0 → 0	499 → 499

각 변수의 표준편차·최솟값·사분위수도 원본과 최종 마스터가 일치합니다. 비구매 고객의 spend=0과 고액 구매값을 보존했습니다.

4. 그룹별 KPI 원천 집계 검증

실험 배정 그룹	행 수	전환 건수	매출 합계(USD)
Mens E-Mail	21,307	267	30,311.69
Womens E-Mail	21,387	189	23,038.11
No E-Mail	21,306	122	13,908.33
합계	64,000	578	67,258.13

각 그룹별 고객 수·전환 수·매출 합계가 원본과 최종 분석 데이터에서 일치합니다. 이는 KPI 입력 데이터 검증이며, 증분 효과·신뢰구간·p값 산출은 포함하지 않습니다.

5. 분석용 데이터셋과 파생 변수

데이터셋	행 × 열	용도
email_analysis_master	64,000 × 13	전체 분석 기준
q1_conversion_customer	64,000 × 3	발송 배정별 전환
q2_email_type_customer	64,000 × 2	이메일 유형별 전환
q3_revenue_customer	64,000 × 4	배정별 고객당 매출
q1_assignment_groups	2 × 4	Q1 집계
q2_email_type_groups	3 × 4	Q2 집계
q3_revenue_groups	2 × 4	Q3 집계

파생 규칙: Mens E-Mail 또는 Womens E-Mail이면 email_assigned=1, No E-Mail이면 0. 값 미매핑 0건, 파생값 오류 0건(전체 64,000행 검사). 질문별 고객 단위 데이터는 동일 원본의 뷰이므로 서로 합산해서는 안 됩니다.

6. 남은 제한 및 후속 작업

① 실제 고객 고유 ID가 없으므로 동일 행 6,562건을 중복 고객으로 확정할 수 없습니다. ② CSV에 일자·시각 컬럼이 없어 원본 문서의 14일 관측 조건을 파일 내부만으로 검증할 수 없습니다. ③ 캠페인 비용·마진이 없어 ROI 판정은 불가능합니다.

최종 판정: EDA 진행 적합. 단, 원본 실험 설계 및 관측 단위는 외부 명세 확인이 필요합니다. EDA는 별도 승인 전까지 미진행입니다.

근거 파일: email_data_integration_verification.json, email_experiment_preprocessing_log.json, validation_manifest.json, 원본 CSV, email_analysis_master.csv.